

Học sâu



Nội dung

1. Giới thiệu

2. Bộ tự mã hóa & kiến trúc sâu

3. Máy Boltzmann & kiến trúc sâu

4. Mạng tích chập

Các bài toán trong học máy

Thống kê cổ điển

- Số chiều **thấp**
- Nhiều nhiều
- Dữ liệu **ít cấu trúc**
- Bài toán chính là **khử nhiễu**

Trí tuệ nhân tạo


- Số chiều **cao**
- Có nhiều vừa phải
- Dữ liệu **có cấu trúc**
- Bài toán chính là **sử dụng cấu trúc để học**

Lịch sử phát triển

Perceptron (1960)

- Dữ liệu → Đặc trưng
- Học = Gán trọng số
- Thuật toán đơn giản
- Nhiều hạn chế cố hữu


$$f(x) = b + \sum_i w_i x_i$$



Lịch sử phát triển

Mạng nơ-ron nhiều tầng (1980)

- Thông tin truyền qua các tầng
- Học = Gán trọng số liên kết
- Thuật toán lan truyền ngược
- *Hi vọng mỗi tầng tăng mức trừu tượng hóa dữ liệu.*




Lịch sử phát triển

SVM (1990)

$$f(x) = b + \sum_i \alpha_i y_i k(\mathbf{x}, \mathbf{x}_i)$$

- Một loại perceptron đặc biệt
- Đặc trưng = khoảng cách từ mẫu mới đến các mẫu huấn luyện
- Cực đại hóa lề (quy hoạch lồi)
- Nhưng vẫn chỉ là perceptron



Điểm yếu của mạng nơ-ron

Cần dữ liệu có nhãn

Thực tế, đa phần dữ liệu không có nhãn.

Tốc độ học chậm

Càng nhiều tầng $\rightarrow$ giá trị đạo hàm càng nhỏ

Dễ mắc vào tối ưu cục bộ

Do học đồng thời tất cả các trọng số

Khó khởi tạo trọng số gần tối ưu “tốt”.


Học cấu trúc của đầu vào

Học $P(\text{mẫu})$ hoặc biểu diễn mới của dữ liệu.

Sử dụng được dữ liệu không có nhãn

Vẫn dùng thuật toán lan truyền ngược để tính đạo hàm

Khởi tạo tham số
cho từng tầng



Nội dung

1. Giới thiệu

2. Bộ tự mã hóa & kiến trúc sâu

3. Máy Boltzmann & kiến trúc sâu

4. Mạng tích chập

Bộ tự mã hóa auto-encoder

Bengio, Ranzato (2007), Vincent (2008)

2 bước: mã hóa (encode) và giải mã (decode)

$$y = \text{sigmoid}(\underbrace{W}_{d' \times d} x + b)$$

$x \Rightarrow y \Rightarrow z \approx x$
Tối thiểu

$$z = \text{sigmoid}(\underbrace{W'}_{d \times d'} y + b')$$


cross-entropy giữa x và z

Bộ tự mã hóa auto-encoder

$$x \Rightarrow y \Rightarrow z \approx x$$

y là biểu diễn của **x** trên
không gian d' chiều.

Tối thiểu cross entropy $\rightarrow$ **y**
chứa nhiều nhất có thể
thông tin từ **x**




Chồng các bộ tự mã hóa

x có thể biểu diễn bởi y

y có thể biểu diễn bởi ... ?

*Chồng các bộ tự mã hóa lên
nhau (sau khi cắt bộ giải mã)*

*Các tầng = Các mức trừu
tượng dữ liệu*




Huấn luyện

Khởi tạo các tầng bằng
các bộ mã hóa

Thêm 1 tầng ẩn và 1
tầng ra để phân lớp

Tinh chỉnh (fine-tuning)
bằng lan truyền ngược



Ưu điểm

Nhiều tầng mạng không cần nhãn để học.

Tận dụng các “mẹo” huấn luyện mạng nơ-ron


Kỹ thuật **điều chỉnh giảm** (regularization)

Kỹ thuật **chia sẻ trọng số** (weight sharing)

Kỹ thuật **học trực tuyến** (online), **nhóm mẫu nhỏ** (mini-batch)

MNIST digits

Vincent (2008) 2,8% (SVM-RBF 3,03%)



Nội dung

1. Giới thiệu

2. Bộ tự mã hóa & kiến trúc sâu

3. Máy Boltzmann & kiến trúc sâu

4. Mạng tích chập


Máy Boltzmann (RBM)

Máy Boltzmann hạn chế

Học cách sinh ra dữ liệu

(**generative model**)

Có thể xếp chồng thành kiến trúc
sâu tương tự Bộ tự mã hóa




Máy Boltzmann

Xác suất liên hợp

$$P(v, h) = \frac{1}{Z} e^{-E(v, h)}$$

$$\begin{aligned} E(v, h) &= - \sum_i a_i v_i - \sum_j b_j h_j - \sum_{i,j} v_i w_{ij} h_j \\ &= -\langle a, v \rangle - \langle b, h \rangle - \langle v, Wh \rangle \end{aligned}$$



Máy Boltzmann


Xác suất có điều kiện

$$P(v|h) = \prod_i P(v_i|h)$$

$$P(h|v) = \prod_j P(h_j|v)$$

$$P(v_i|h) = \text{sigmoid}(a_i + \sum_j w_{ij}h_j)$$

$$P(h_j|v) = \text{sigmoid}(b_j + \sum_i w_{ij}v_i)$$



Máy Boltzmann

Huấn luyện (Gibbs sampling)

Lấy mẫu

$$h^{\text{data}} \sim P(h|v^{\text{data}})$$

Lấy mẫu


$$v^{\text{recon}} \sim P(v|h^{\text{data}})$$

Lấy mẫu

$$h^{\text{recon}} \sim P(h|v^{\text{recon}})$$

Cập nhật

$$\Delta W = \epsilon((vh^T)_{\text{data}} - (vh^T)_{\text{recon}})$$



Kiến trúc sâu

RBM lấy mẫu theo xác suất có điều kiện


Cách lấy mẫu $\mathbf{v}^{\text{data}} \rightarrow \mathbf{h}^{\text{data}} \rightarrow \mathbf{v}^{\text{recon}} \rightarrow \mathbf{h}^{\text{recon}}$

Xây dựng lại dữ liệu như bộ tự mã hóa.


Như vậy có thể **xếp chồng các RBM** để tạo kiến trúc sâu.

Tinh chỉnh trọng số bằng lan truyền ngược

Hinton (Science, 2006)



Hinton (Science, 2006)




Nội dung

1. Giới thiệu
2. Bộ tự mã hóa & kiến trúc sâu
3. Máy Boltzmann & kiến trúc sâu
4. Mạng tích chập

Mạng tích chập

Convolutional Neural Networks (CNN)

Mô phỏng quá trình nhìn của động vật




Mạng tích chập

Liên kết thưa

Lớp thứ $m+1$


Lớp thứ m

Lớp thứ $m-1$



Mạng tích chập

Chia sẻ trọng số $\rightarrow$ đặc trưng




Học đặc trưng

Lấy mẫu ngẫu nhiên các vùng
nhỏ trên ảnh

Học biểu diễn hoặc phân bố
bằng bộ tự mã hóa hoặc RBM

Mỗi nơ-ron ẩn là một đặc trưng



Tầng lấy mẫu (pooling)

Chia ảnh thành các vùng nhỏ (xen kẽ)

2×2 , 3×3

Mỗi vùng chỉ lấy giá trị **lớn nhất**

Giảm kích cỡ ảnh cho tầng tiếp theo


Tăng tính phi tuyến

Tăng tính bất biến (với biến đổi hình học)

Mạng Lenet

Cho kết quả tốt nhất trên dữ liệu MNIST

Ciresan (2012): 0.23%



Các ứng dụng khác

Văn bản (**word2vec**)

Bộ tự mã hóa cho từ vựng

Huấn luyện bằng tập văn bản (corpus)

Mỗi từ = một véc-tơ nhiều chiều

Hanoi - Vietnam = Moscow - Russia

Đầu vào cho các kiến trúc sâu

Google, Lê Việt Quốc

Các ứng dụng khác

Nhận dạng tiếng nói (**speech recognition**)

Trước đây dùng đặc trưng thiết kế bởi con người

MFCC → Gaussian Mixture Model

Học sâu: dùng **bộ tự mã hóa** để phát hiện đặc trưng

Mạng tích chập

Chính xác hơn MFCC + GMM + HMM

Tổng kết

Học sâu là học các mức trừu tượng hóa dữ liệu đầu vào.

Học sâu dùng dữ liệu không có nhãn để khởi tạo các tầng tự mã hóa.

Học sâu có thể áp dụng trên ảnh, văn bản, âm thanh.

Tham khảo

Bài giảng có tham khảo một số bài giảng của Hinton, Vincent, Bengio.