

ĐỀ THI HỌC PHẦN KHOA HỌC DỮ LIỆU

HỌC KỲ II, NĂM HỌC 2024 – 2025


Thời gian làm bài: 80 phút

Đề thi gồm: 04 trang

Sinh viên KHÔNG được phép sử dụng tài liệu. Cán bộ coi thi KHÔNG giải thích gì thêm.

Phần TRẮC NGHIỆM - 30 câu

Với các phát biểu dưới đây (từ câu 1 đến câu 21), hãy trả lời bằng cách lựa chọn Đúng hay Sai? Đồng thời phải giải thích tại sao bằng 1 đến 2 câu.

- S 1. Nếu khoảng tin cậy (confidence interval) 95% cho trung bình điểm thi của sinh viên là $[5, 8]$, thì chúng ta có thể chắc chắn rằng trung bình điểm thi của toàn bộ sinh viên nằm trong khoảng này.
- S 2. Việc ngẫu nhiên hóa (randomization) đảm bảo rằng người thực hiện thí nghiệm không biết rằng đối tượng tham gia thí nghiệm thuộc nhóm nghiên cứu (treatment group) hay nhóm đối chứng (control group).
- D 3. Trung bình của tổng thể phân phối (population mean) là một giá trị thống kê (statistic).
- S 4. Chúng ta có mẫu dữ liệu chiều cao và cân nặng của 200 cá nhân trong một mẫu lấy từ quần thể gồm 2000 người. Biểu đồ tần số (histogram) có thể được sử dụng để xem liệu có mối liên hệ giữa chiều cao và cân nặng của các cá nhân hay không.
- S 5. Một nhà phân tích dữ liệu muốn thể hiện tỷ lệ sinh viên tốt nghiệp đúng hạn theo từng khoa trong một trường đại học. Người này sử dụng biểu đồ đường (line plot) để trình bày dữ liệu này, với trục hoành là tên các khoa và trục tung là phần trăm sinh viên tốt nghiệp đúng hạn. Cách làm với biểu đồ như vậy là hợp lý. 
- D 6. Bốn thành viên trong nhóm (A,B,C,D) đã tham gia thử vai để biểu diễn một hoạt động trong video TikTok quảng bá cho khóa học. Giáo sư chọn ngẫu nhiên một người trong số họ (với xác suất bằng nhau). Người được chọn sau đó sẽ chọn ngẫu nhiên một trong ba hoạt động — diễn xuất, nhảy hoặc hát — để thực hiện trong video. Xác suất người được chọn không phải là A và người này chọn hoạt động là nhảy là 0.25. $\frac{3}{4} \cdot \frac{1}{3}$
- S 7. Nếu phân phối (distribution) của một tập dữ liệu là lệch phải (right-skewed), thì trung bình (mean) luôn nhỏ hơn trung vị (median).
- S 8. Biểu đồ tốt nhất để hiểu phân phối của 5 món ăn phổ biến nhất là đồ thị phân tán (Scatter plot).
- D 9. Việc áp dụng mô hình hồi quy tuyến tính giả định mối quan hệ tuyến tính giữa biến độc lập (predictor variable) và biến phụ thuộc (response variable).
- D 10. Câu lệnh `group_by` của thư viện `datascience` được sử dụng để tính toán tổng, trung bình hoặc đếm số lượng, giá trị nhỏ nhất (min), ... theo từng nhóm trong dữ liệu.
- X 11. Bảng tổng hợp (pivot table) có thể giúp trình bày dữ liệu theo dạng bảng 2 chiều, với biến ở hàng, cột và giá trị được tính toán.
- D 12. Để xây dựng một bộ phân lớp Láng giềng gần nhất (k-Nearest Neighbor) sử dụng toàn bộ tập huấn luyện (training set), bạn chỉ cần biết nhãn của lớp (label) một số điểm dữ liệu chứ không cần biết nhãn của toàn bộ tập dữ liệu.

$$\text{inter} = SD y - \text{slope} \cdot SD x$$

13. Nếu sử dụng hồi quy tuyến tính để dự đoán biến y dựa trên biến x , trong đó cả x và y đều được chuẩn hóa (standardized), hệ số tự do (intercept) có thể có giá trị nhỏ hơn 0.
14. Theo định lý giới hạn trung tâm (Central Limit Theorem), nếu một tập mẫu là lớn, và được lấy mẫu ngẫu nhiên có hoàn lại từ dân số (population), thì phân phối xác suất của trung bình mẫu là xấp xỉ phân bố chuẩn (roughly normal distribution).
15. Đồ thị phần dư (residual plot) của một hồi quy (regression) giúp xác định xem phương pháp hồi quy đang dùng có phù hợp với bài toán hay không.
16. Trong A/B test, chúng ta hoán vị nhãn (label) dữ liệu là để đảm bảo rằng các đối tượng được gán ngẫu nhiên vào các nhóm nghiên cứu (treatment group) và nhóm đối chứng (control group).
17. Việc phân chia dữ liệu thành tập huấn luyện (training set) và tập kiểm tra (test set) nên áp dụng cho bài toán Phân nhóm (classification), nhưng không nên cho bài toán Hồi quy đa biến (Multiple Regression).
18. Trong đồ thị tần suất (histogram), chiều cao của mỗi cột (bar) biểu diễn tỷ lệ phần trăm của các phần tử (entries).
19. Tung đồng xu đối xứng N lần. Cả hai Luật số lớn (Law of large number) và Định lý giới hạn trung tâm (Central limit theorem) đều cho biết rằng khi N càng lớn thì tỷ lệ số lần sấp chia cho số lần ngửa ($\#sấp/\#ngửa$) càng gần với $1/2$.
20. Một thống kê cho thấy tỷ lệ học sinh trường A có tỷ lệ vào đại học cao hơn nhiều các trường khác. Như vậy thống kê đó giúp có kết luận: giáo viên và chương trình học của trường A là lý do giúp học sinh đỗ đại học cao.
21. Phương pháp tạo mẫu ngẫu nhiên (bootstrap) giúp xác định khoảng tin cậy (confidence interval), nhưng không nên dùng trong kiểm định giả thuyết (hypothesis test).

Theo một báo cáo số người nhập viện do cúm năm nay ở địa phương X tăng. Vì không có báo cáo tương tự trong quá khứ, bạn muốn biết tỷ lệ mắc cúm (tỷ lệ dân số bị nhiễm virus cúm) ở X năm nay có cao hơn bình thường hay không. Do bạn chỉ có nguồn lực để tiến hành khảo sát ngẫu nhiên 1000 người, bạn quyết định thực hiện kiểm định giả thuyết để tìm hiểu. Sau khi khảo sát ngẫu nhiên 1000 người, bạn thấy tỷ lệ mắc bệnh trong mẫu là 0.35. Trong lịch sử hiện đại (kể từ khi vaccine cúm được phát minh), tỷ lệ mắc bệnh dự kiến là 0.2. Các phát biểu sau đây (từ câu 22 đến câu 25) là Đúng hay Sai? Đồng thời phải giải thích tại sao bằng 1 đến 2 câu.

22. Giả thuyết rỗng (null) H_0 : Tỷ lệ thực sự của bệnh cúm năm nay là 0.2, và bất kỳ sự sai lệch nào so với tỷ lệ này đều là do sự ngẫu nhiên trong việc chọn mẫu.
23. Giả thuyết đảo (alternative) H_A : Tỷ lệ thực sự của bệnh cúm năm nay nhỏ hơn 0.2.
24. Thống kê (statistic) phù hợp cho kiểm định này là số lượng các trường hợp bị nhiễm cúm trong mẫu khảo sát trên.
25. Bạn tìm được p-value là 0.04. Với mức ý nghĩa (cutoff hay α) là 0.03, bạn không thể bác bỏ giả thuyết H_0 .

$$p\text{-value} = 0.04 > 0.03$$

p > 0.03 → support H_0

Dữ liệu thu thập về các bài viết của một trang báo điện tử có trong bảng Tin_tức, với 4 dòng đầu tiên, như sau:

#tiêu_đề	#nội_dung	chủ_đề	thể_loại	#thời_gian (s)	#bình_luận <i>đ</i>
11	41	Văn hóa	Video	90	16
12	728	Thể thao	Text	150	258
12	947	Thời sự	Text	20	1
12	30	Thể thao	Video	10	0

Trong đó (# dùng cho các biến loại số lượng):

- #tiêu_đề: số nguyên, số từ (độ dài) của tiêu đề bài viết
- #nội_dung: số nguyên, số từ (độ dài) của nội dung bài viết
- chủ_đề: text, phân nhóm tin tức
- thể_loại: text, loại tin video hay text (văn xuôi)
- #thời_gian: số nguyên, thời gian (theo giây) xem trung bình của người đọc
- #bình_luận: số nguyên, số bình luận của người đọc

Với các câu hỏi 26-30, hãy chọn một kỹ thuật phù hợp nhất để trả lời câu hỏi. Sinh viên phải trả lời a hoặc b hoặc c hoặc d; và phải có giải thích ngắn gọn.

26. Cho biết #nội_dung, hãy tìm thể_loại của bài viết?

- ☒ Classification (Phân nhóm)
- ☐ Linear Regression (Hồi quy tuyến tính)
- ☐ Hypothesis Test (Kiểm định giả thuyết)
- ☐ Randomized Control Experiment (Thí nghiệm có đối chứng ngẫu nhiên)

27. Cho biết #nội_dung và #thời_gian, hãy tìm #bình_luận?

- ☐ Classification (Phân nhóm)
- ☒ Linear Regression (Hồi quy tuyến tính)
- ☐ Hypothesis Test (Kiểm định giả thuyết)
- ☐ Randomized Control Experiment (Thí nghiệm có đối chứng ngẫu nhiên)

28. Có hay không sự khác biệt về #tiêu_đề giữa tin tức của hai thể_loại "Video" và "Text"?

- ☐ Classification (Phân nhóm)
- ☐ Linear Regression (Hồi quy tuyến tính)
- ☒ Hypothesis Test (Kiểm định giả thuyết)
- ☐ A/B Testing (Thử nghiệm A/B)

29. Để tìm hiểu mối quan hệ giữa #thời_gian và #bình_luận?

- ☐ Line graph (Đồ thị đường)
- ☐ Histogram (Biểu đồ tần suất)
- ☒ Scatter plot (Đồ thị phân tán)
- ☐ Overlaid Scatter Plots (Các đồ thị phân tán chồng nhau)

- + nội dung
30. So sánh độ dài trung bình của các bài báo theo mỗi nhóm chủ đề?
- Line graph (Đồ thị đường)
 - Histogram (Biểu đồ tần suất)
 - Bar chart (Biểu đồ cột)
 - Scatter plot (Đồ thị phân tán)

Phần TỰ LUẬN - 2 câu

31. Bạn xây dựng một mô hình để dự đoán liệu một email là thư rác (spam) hay không, dựa trên số lượng từ khóa quảng cáo xuất hiện, cũng như số từ trong nội dung. Bạn có bảng emails gồm 3 cột:

- keyword_count: số lượng từ khóa quảng cáo
 - total_count: số từ của toàn bộ nội dung email
 - is_spam: nhãn phân lớp (1 nếu là spam, 0 nếu không phải spam)
- Trình bày các bước xây dựng mô hình phân lớp cho bài toán này sử dụng thuật toán Láng giềng gần nhất (k-Nearest Neighbor).
 - Giải thích lý do cần sử dụng tập huấn luyện (training set) và tập kiểm tra (test set) để đánh giá mô hình.
 - Nếu mô hình có độ chính xác 92% trên tập huấn luyện nhưng chỉ 75% trên tập kiểm tra, bạn rút ra kết luận gì, có thể cải thiện như thế nào?

32. Trong trò chơi Tiến lên online, mỗi người được chia 13 trong tổng số 52 quân bài Tú lơ khô (2-10, J, Q, K, A; với các chất rô, cơ, bích, tép). Sau khi chia bài, một người được bộ ba liên tiếp là khi người đó có ba quân bài cùng chất có thứ tự liên tiếp nhau. (Ví dụ: 4, 5, 6 cơ; hay J, Q, K tép.)

Trong các câu hỏi dưới đây, sinh viên chỉ cần nêu phương pháp, cùng với các bước cần thiết (tính toán, công thức, mã giả, code,...) để tìm ra lời giải; Không cần nêu giá trị cụ thể cần tính hay kết luận cuối cùng.

- Hãy ước lượng tỷ lệ phần trăm một người chơi X có được ít nhất một bộ ba liên tiếp sau mỗi lần chia bài.
- Sau khi chơi 100 ván, một người X tự đếm được tổng cộng có 30 ván có được ít nhất một bộ ba liên tiếp sau khi chia. Người X nghĩ việc chia bài có thể có gian lận bất lợi cho mình. Hãy giúp người X có được câu trả lời cho nghi ngờ trên.

bootstrap [30; 10] — HẾT —
 → Lấy lại 30 : 1
 70 : 0
 → Mang số 30 ván
 100 bootstrap

H_0 : Chia bài có gian lận gây bất lợi.
 H_A : Chia bài ko gian lận gây bất lợi.